


HTK Label Refinement

一、概要

HTK切的lab並不是很準確，為了修正這個問題，我們引入了spectral KL distance來輔助修正lab，並利用Viterbi演算法來選擇最好的spectral KL distance以及HMM unit (initial, final, or phoneme)的長度 (duration)組合。下面介紹如何計算spectral KL distance和Viterbi演算法的細節。

二、Spectral KL Distance

在介紹spectral KL distance怎麼計算之前要先介紹子頻段信號波峰，它將頻譜分成比較有意義的六個頻段，方便分析也用來算出spectral KL distance。



圖一:KL distance流程圖

圖一是KL distance的計算流程圖，六個濾波器都用Hamming window，再40Hz的低通濾波器獲得六個頻帶的信號包絡，這40Hz的低通濾波器階數要比較高。最後，用這六個頻帶的信號包絡算出KL distance。

distance的計算流程有用低階數的濾波器來通過整流器，獲得六個頻帶的信號包絡，這40Hz的低通濾波器階數要比較高。最後，用這六個頻帶的信號包絡算出KL distance。

1. 子頻段信號波峰


在語言學家所提出的聲學參數中，有許多帶通濾波器能量，他們各自能用來區別不同的發音方式和發音位置，本方法用的頻段如下：

0.0 – 0.4 kHz 0.8 – 1.5 kHz 1.2 – 2.0 kHz

2.0 – 3.5 kHz 3.5 – 5.0 kHz 5.0 – 8.0 kHz

語言學家所使用的聲學參數為這些頻段信號波峰，為了增加運算的速度，本方法的波峰檢測器不用Hilbert transform，而是通過一個整流器，將振幅小於等於0的部分拿掉。最後，通過40Hz的低通濾波器獲得頻段信號的包絡，注意音檔振幅要正規化到1到0之間。


截止頻率為 f_l ($\omega_l = \frac{f_l}{f_s} * \pi$)的低通濾波器設計如下：




圖二:截止頻率為的低通濾波器頻率響應圖

$$\begin{aligned}
 h_{lowpass}[n] &= \frac{1}{2\pi} \int_{-\omega_l}^{\omega_l} 1 * e^{j\omega n} d\omega = \frac{1}{2\pi j n} (e^{j\omega_l n} - e^{-j\omega_l n}) = \frac{1}{\pi n} \left(\frac{e^{j\omega_l n} - e^{-j\omega_l n}}{2j} \right) \\
 &= \frac{1}{\pi n} \sin \sin(\omega_l n) = \omega_l \text{sinc}(\omega_l n) \quad (1)
 \end{aligned}$$

而截止頻率為 $f_l \sim f_h$ ($\omega_h = \frac{f_h}{f_s} * \pi$) 的帶通濾波器就是將截止頻率 f_h 的低通濾波器減截止頻率 f_l 的低通濾波器如下:



圖三:截止頻率為的低通濾波器頻率響應圖



圖四：帶通濾波器頻率響應圖

$$h_{bandpass}[n] = \omega_h \text{sinc}(\omega_h n) - \omega_l \text{sinc}(\omega_l n) \quad (2)$$

2. Spectrum KL Distance

KL distance原本是用在描述兩個機率分布的差異或是距離，比如有兩個隨機變數 p 以及 q ，它們都是有 I 個 event，則兩個隨機變數 p 之於 q 對應的機率分布之間的 KL distance 為：

$$D_{KL}(p||q) = \sum_{i=1}^I p_i \ln \frac{p_i}{q_i} \quad (3)$$

如果是隨機變數 q 之於 p 對應的機率分布之間的 KL distance 為：

$$D_{KL}(q||p) = \sum_{i=1}^I q_i \ln \frac{q_i}{p_i} \quad (4)$$

在本系統是想要利用 KL distance 來量測兩的時間點(boundary附近的兩點) spectral envelope 的差異，所以我們先把兩個時間點的帶通頻段信號包絡線正規化成符合機率假設：

$$\hat{E}_i[n] = \frac{E_i[n]}{\sum_{j=1}^6 E_j[n]} \quad (5)$$

其中 $E_i[n]$ 代表第 n 個 sample 點對應到的第 i 個頻帶信號包絡線值，而 $\hat{E}_i[n]$ 就是機率正規化後的信號包絡線值。第 n 個 sample 點的 $d_{KL}[n]$ 是以第 $n - N$ 點和第 $n + N$ 點的規化信號包絡線值來計算 symmetric KL distance：

$$d_{KL}[n] = \frac{1}{2} D_{KL}(\hat{E}[n - N] || \hat{E}[n + N]) + \frac{1}{2} D_{KL}(\hat{E}[n + N] || \hat{E}[n - N]) = \frac{1}{2} \sum_{i=1}^6 (\hat{E}_i[n - N]) \ln \left(\frac{\hat{E}_i[n - N]}{\hat{E}_i[n + N]} \right) + \frac{1}{2} \sum_{i=1}^6 (\hat{E}_i[n + N]) \ln \left(\frac{\hat{E}_i[n + N]}{\hat{E}_i[n - N]} \right) \quad (6)$$

N 在本方法中是取距離目前點數前後 5ms 的點，以取樣率 16k 為例，就是前後 80 點

, 目前第 n 點前的80點和第 n 點後的80點來計算。

三、Viterbi for Fixing Voiced/Unvoiced Edge in HTK Lab

我們用 d_{KL} 來輔助修正voiced/unvoiced的邊界(以下簡稱uv邊界), d_{KL} 的值在uv邊界會比較大, 我們可以利用這個特性來修正那些不符合語音特性的lab。

1. 定義邊界

信號中的點我們分成5種類型: unvoiced speech segment (HMM unit)標記為0, voiced speech segment標記為1, short pause長度大於0的標記為2, short pause長度等於0的標記為2.5, silence標記為3, 而uv邊界為1 uv boundary $\rightarrow$ 0、0 uv boundary $\rightarrow$ 1、1 uv boundary $\rightarrow$ 2.5 uv boundary $\rightarrow$ 0、0 uv boundary $\rightarrow$ 2.5 uv boundary $\rightarrow$ 1, 在新的做法中, 預先將2.5的部分移除, 這樣uv邊界就只有1 uv boundary $\rightarrow$ 0、0 uv boundary $\rightarrow$ 1兩種狀況, 修正完後再比對HTK lab給予2.5的部分。

2. 參數定義

我們定義HTK lab裡面的切割 (boundary) 數量為 N , 也就是lab檔有 N 行, S_n 代表第 n 個HTK切割, $t(S_0)$ 是第一個HTK切割的起始時間點, $t(S_1)$ 是第一個切割的(結束)時間點, $t(S_2)$ 是第二個切割的時間點, 以此類推到 $t(S_N)$ 為最後一個切割時間點。

S_n 附近有 m_n 個boundary candidates, 這些candidates為時間點 $t(S_{n-1})$ 到時間點 $t(S_{n+1})$ 之間 $d_{KL}[\cdot]$ 前 m_n 個KL的peak值, peak的定義為該點的值大於前一點的值和後一點的值。所以 $C_{n,i}$ for $i = 1, 2, \dots, m_n$ 是 S_n 附近前 m_n 個KL peak值的candidate boundary。若 S_n 不是uv boundary, 則 $m_n = 1$ 且 $C_{n,1} = S_n$, S_N 為最後一個切割位置, 其實就是句尾的sil結束時間, $m_N = 1$ 且 $C_{N,1} = S_N$ 。以下我們將Viterbi裡面使用到的terms列出並做說明:

- $d_{KL}[t(S_n)]$: 第 n 個HTK boundary的時間點對應的KL值。
- $d_{KL}[t(C_{n,i})]$: Viterbi裡面的local score第 n 個boundary的第 i 個candidate的時間點對應的KL值。
- $w1$: local score的權重, 為正值。
- $t(S_n) - t(S_{n-1})$: 第 n 個speech segment的duration。
- $t(C_{n,i}) - t(C_{n-1,j})$: 由candidate boundaries $C_{n,i}$ 以及 $C_{n-1,j}$ 構成的speech segment duration
- $((t(C_{n,i}) - t(C_{n-1,j})) - (t(S_n) - t(S_{n-1})))^2$: Viterbi演算法裡面的transition cost。
- $w2$: Viterbi演算法中的transition cost的weight, 為負值。
- $\alpha_n(i)$: forward variable, 累計假設目前第 n 個boundary的candidate為 $C_{n,i}$ 情況下最好的累計score。
- $p_n(i)$: backtrace pointer, 紀錄第 n 個boundary的candidate為 $C_{n,i}$ 情況下, $n-1$ 個切割最好的candidate, 也就是 $p_n(i) \in \{1, 2, \dots, m_{n-1}\}$ 。
- b_n : Viterbi backtrace後, 得到第 n 個boundary最好的切割candidate index, $b_n = 1 \sim m_n$, 而 $t(C_{n,b_n})$ 也就是切割修正的結果。

3. Viterbi流程

此流程希望能使用dynamic programming的方法找到最後的uv boundary使得這些uv boundary所累計的KL值儘量大以及對應的speech segment長度相近於原本HTK切出的speech segment duration。以下說明此演算法：

- Initialization:

$$\alpha_1(i) = w1 * d_{KL}[t(C_{1,i})] + w2((t(C_{1,i}) - t(S_0)) - (t(S_1) - t(S_0)))^2$$

for $i = 1 \sim m_1$, m_1 為第一個切割的candidate總數 (7)

$$p_1(i) = S_0 \quad (8)$$

- Iteration:

$$\{w1 * d_{KL}[t(C_{n,i})] + w2((t(C_{n,i}) - t(C_{n-1,j})) - (t(S_n) - t(S_{n-1})))^2 + \alpha_{n-1}(j)\}$$

for $n = 2 \sim N$, $i = 1 \sim m_n$; m_n 為 n 個切割的candidate總數 (9)

$$p_n(i) = \arg \arg \{w1 * d_{KL}[t(C_{n,i})] + w2((t(C_{n,i}) - t(C_{n-1,j})) - (t(S_n) - t(S_{n-1})))^2 + \alpha_{n-1}(j)\}$$

for $n = 2 \sim N$, $i = 1 \sim m_n$; m_n 為 n 個切割的candidate總數 (10)

- Termination and backtracking:

$$b_N = 1 \quad (\text{最後一個切割只有一個candidate}) \quad (11)$$

$$b_{n-1} = p_n(b_n) \quad \text{for } n \text{ from } N \text{ to } 1 \quad (12)$$

修正後的切割位置時間就是 $t(C_{n,b_n})$ for $n = 0 \sim N$

四、Short Pause Boundary Correction Method

在前一節viterbi的修正中，發現short pause(以下簡稱sp)的邊界切的不好，導致後面的邊界會往前切，所以sp的邊界也需要修正，本節先介紹論文中的修正方法，再詳述修正sp邊界的方法。

1. 論文中的修正方法

(1) 前端點:在原端點位置前後30ms的範圍內，判斷信號包絡是否小於信號包絡之臨限值而得到一個交集點，再經由交集點附近距離10ms內來判斷六個頻段信號包絡是否皆小於該頻段信號包絡之臨限值的條件做交集來決定是否有短停頓的狀態。

(2) 後端點:在原端點位置之前後30ms的範圍內，判斷信號包絡是否大於信號包絡之臨限值而得到一個交集點，再經由交集點附近距離10ms內來判斷六個頻段信號包絡是否皆大於該頻段信號包絡之臨限值的條件做交集來決定是否有短停頓的狀態。

(前端點為short pause的起始點，後端點為short pause的結束點。)

信號包絡之臨限值	Thd_{env_signal}
第一個頻段信號包絡之臨限值	$Thd_{env_filter1}$
第二個頻段信號包絡之臨限值	$Thd_{env_filter2}$
第三個頻段信號包絡之臨限值	$Thd_{env_filter3}$
第四個頻段信號包絡之臨限值	$Thd_{env_filter4}$
第五個頻段信號包絡之臨限值	$Thd_{env_filter5}$
第六個頻段信號包絡之臨限值	$Thd_{env_filter6}$

臨限值是統計(以語者為單位)音檔頭尾前後的silence，其包絡之平均作為臨限值，六個頻段之臨限值亦是如此。以取樣率為16k為例，30ms為480點，10ms為160點，令目前端點的index為 n ，訊號為 x ，各頻段包絡為 $x1 \sim x6$ ，交集點的index為 n ，論文中前端點的做法如下：

在原端點 n 附近30ms的範圍尋找符合下述的條件

$$x[n] < Thd_{env_signal}, \quad n - 480 \leq n \leq n + 479$$

之後再 n 前後10ms的範圍尋找符合下述的條件

$$x1[n] < Thd_{env_filter1}, \quad n - 160 \leq n \leq n + 159$$

$$x2[n] < Thd_{env_filter2}, \quad n - 160 \leq n \leq n + 159$$

$$x3[n] < Thd_{env_filter3}, \quad n - 160 \leq n \leq n + 159$$

$$x4[n] < Thd_{env_filter4}, \quad n - 160 \leq n \leq n + 159$$

$$x5[n] < Thd_{env_filter5}, \quad n - 160 \leq n \leq n + 159$$

$$x6[n] < Thd_{env_filter6}, \quad n - 160 \leq n \leq n + 159$$

如果都符合上述條件, n' 就為短停頓的前端點。後端點的作法和前端點一樣, 差異在條件, $x[n']$ 是要大於 Thd_{env_signal} 且各頻段之包絡也要大於各頻段之臨限值, 如果都符合則為短停頓的後端點。

2. 本方法提出的短停頓修正流程

在觀察viterbi的修正結果中, 我們發現sp的後端點很多時候切的不夠長, 所以我們針對sp的後端點進行修正(htk切出有時長不為0的sp)。

在sp的後端點位置往後60ms的範圍, 判斷信號包絡是否大於信號包絡的threshold而得到一個交集點, 再經由交集點前後10ms內來判斷六個頻段之信號包絡是否大於該頻段之信號包絡的threshold, 若所有頻段信號包絡都符合條件就決定該交集點為sp的後端點。由於觀察到的後端點都是切得太短, 所以改成原後端點後60ms的長度, 條件都和論文中的後端點一致, n' 為最終後端點。

Reference

1. You-Yu Lin and Yih-Ru Wang, “Phonetic Segmentation using Sample-based Acoustic Parameters”